

RAG 검색 평가 (Ground Truth 기반)

테스트 계획 및 결과 보고서

대상 시스템: 사내 지식 챗봇 (RAG + Text2SQL) — 문서 검색(RAG) 모듈

평가 방법: 하이브리드 검색 후보 Top-30 × LLM Judge 0~3점 관련성 라벨링

질문 셋: 100문항 (question.csv) | 총 판정 건수: 3,000건

1. 개요

1.1 목적

사내 지식 챗봇의 **RAG**(문서 검색 기반 답변) 모듈이 실제로 관련 문서를 상위 순위에 올바르게 검색해오는지를 정량적으로 측정한다. 사람이 매번 눈으로 검색 결과를 확인하는 대신, 미리 만든 정답지(**qrels**)를 기준으로 **Recall**, **Precision**, **MRR**, **nDCG** 지표를 계산하여 현재 검색 품질의 기준선(**baseline**)을 확보하고, 품질이 떨어지는 지점(질문 유형·문서 영역)을 구체적으로 식별하는 것이 목적이다.

1.2 범위 및 전제

- 본 테스트의 대상은 **RAG** 검색·평가 파이프라인(질문 → 하이브리드 검색 → LLM 관련성 판정 → 지표 계산)이며, 채팅 **UI**/프론트엔드 기능(예: 웹검색 전환 표시 배지, 이상탐지 대시보드 **GUI**)은 이번 테스트 범위에 포함되지 않는다. 해당 기능들은 별도 진행 상태이며 이 보고서와 독립적이다.
- **Text2SQL**(구매/판매 DB 질의) 영역은 이번 테스트 대상이 아니다. 다른 팀원이 별도로 진행 중이며 파일 겹침이 없음을 확인했다.
- **qrels**는 LLM Judge가 생성한 초안이며, 문서 8절 rubric에 따라 2점·3점 판정 및 애매한 사례는 사람 재검토를 거쳐야 **golden set**으로 확정된다. 본 보고서의 지표는 사람 검토 이전 단계의 LLM Judge 라벨을 기준으로 산출되었다는 점을 명시한다(9절 한계점 참고).

2. 테스트 대상 시스템

문서 검색은 벡터 검색(임베딩 기반)과 어휘 검색(키워드 기반)을 병합하는 하이브리드 방식(**FAISS** 인덱스)을 사용한다. 질문이 들어오면 두 방식 각각 상위 후보를 뽑아 점수 기준으로 병합·정렬한 뒤, 상위 **chunk**를 근거로 답변을 생성한다. 평가 대상 인덱스 버전은 단일 실행 기준으로 일관되게 고정되어 있음을 확인했다(버전 태그: **v1787555278-f3d950ed**, 체크 수는 실행 로그 기준 확인됨).

3. 테스트 방법론

3.1 Ground Truth(**qrels**) 제작 방법

팀 공유 문서(**RAG_검색_평가_Ground_Truth_라벨링_가이드.md**)의 방법론을 그대로 코드화한 스크립트(**rag_ground_truth_label.py**)를 사용했다.

- 질문 100개 각각에 대해 하이브리드 검색으로 상위 30개 후보 chunk를 수집
- 각 (질문, chunk) 쌍을 LLM Judge에게 제시하여 0~3점 관련성 점수와 근거(reason)를 받음
- 결과를 사람이 검토·수정 가능한 CSV(qrels 확장 형식)로 저장 — 이것이 '정답지'가 된다

LLM Judge 채점 기준 (rubric)

점수	판정 기준
0	질문의 답이나 근거와 무관하다
1	같은 주제·키워드를 다루지만 질문에 답하기에는 부족하다
2	질문의 중요한 부분을 답하지만, 조건·예외·세부 정보가 부족하거나 다른 chunk와 결합해야 한다
3	질문의 핵심을 직접 답하며, 이 chunk만으로 신뢰할 수 있는 답변 근거가 된다

※ 정책 판단 시 대상·시점·예외 조건이 다르면 높은 점수를 주지 않도록 설계됨(문서에 없는 사실 추론 금지).

3.2 평가 지표 정의

qrels CSV(query_id, query, chunk_id, relevance)만으로 자기완결적으로 계산되는 지표를

사용했다(rag_eval_metrics.py). 별도의 실시간 검색 결과 파일은 필요하지 않으며, qrels 자체가 '검색했더니 이 chunk가 나왔고 몇 점이었다'는 정보를 담고 있다.

- Recall@k : 상위 k개 중 정답(relevance $\geq$ threshold) chunk를 얼마나 포함했는가
- Precision@k : 상위 k개 중 실제 정답 비율
- MRR (Mean Reciprocal Rank) : 첫 정답이 나온 순위의 역수 평균
- nDCG@k : 0~3점 원점수(graded relevance)를 그대로 반영한 순위 품질 — threshold 이분화의 영향을 받지 않음

※ qrels에 라벨이 없는 chunk가 검색 결과에 나오면 관련성 0으로 취급하는 표준 IR 관례를 따른다. Top-30으로 후보 pool을 좁혔기 때문에, 진짜 정답인데 라벨이 없어 0으로 깎이는 chunk가 있을 수 있음을 감안해 해석해야 한다.

4. 테스트 절차 및 진행 이력

단계	작업	내용 및 결과
1	질문 셋 준비	업무 도메인 100문항(question.csv) 구성 완료

2	1차 라벨링 실행	rag_ground_truth_label.py 실행 → 100문항 × 30후보 = 3,000건 판정 시도 → qrels_draft.csv 생성
3	이슈 발견	3,000건 중 152건(5.1%)이 OpenAI RateLimitError로 재시도 5회 소진 후 실패 — relevance=0으로 기록되었으나 사유(reason)에 실패 표시가 남아 '진짜 무관'과 구분 가능했음
4	실패 건 재판정	실패 152건만 별도 스크립트(retry_failed_judgments.py)로 재판정. 검색(임베딩+FAISS) 단계를 생략하고 이미 확보된 chunk_id로 원문을 직접 조회해 판정만 재실행 → 152건 전부 성공, 원래 성공했던 2,848건은 변경 없음을 검증
5	정답지 확정(초안)	qrels_retried.csv — 3,000건 전체 판정 완료. 이번 보고서의 지표 산출 기준
6	지표 계산	rag_eval_metrics.py를 relevance-threshold 2(rubric 기본값)와 1(완화 기준) 두 조건으로 각각 실행하여 비교

5. 발견된 이슈 및 조치

이슈	영향 및 원인	조치 및 상태
LLM Judge 호출 실패(RateLimitError)	3,000건 중 152건(5.1%), 100문항 중 70문항에 최소 1건 이상 분산. 세마포어(동시 호출 제한)와 지수 백오프 재시도를 적용했음에도 완전히 재현되지는 않음	실패 건만 별도 재판정 스크립트로 100% 회수 완료. 조치 완료
'정답 없음' 질문 다수 발생	relevance≥2 기준 50문항, relevance≥1 기준 19문항이 상위 30개 후보 중 정답 후보가 전혀 없음	재판정 전후로 동일한 19문항이 반복 확인되어 판정 실패의 부작용이 아닌 실제 검색/커버리지 이슈로 판단. 원문 확인은 후속 조치 필요
qrels 재현성 취약	인덱스 버전(index_version, 랜덤 UUID)만 기록되고 chunk_size·overlap·embedding_backe nd 등 생성 조건이 별도로 남지 않음	이번 실행은 단일 버전으로 일관되어 결과 자체는 유효하나, 스크립트 보강은 미착수

6. 테스트 결과

6.1 라벨링 결과 개요

최종 확정된 qrels_retried.csv(3,000건) 기준 relevance 점수 분포는 다음과 같다.

점수	건수	비율	해석
0	2,391	79.7%	완전 무관 — 30개 후보군 특성상 자연스러운 비중
1	479	16.0%	주제는 맞으나 단독 답변 근거로는 부족
2	92	3.1%	핵심 답변 가능하나 세부조건 부족
3	38	1.3%	단독으로 완결된 정답 근거

※ 재판정 대상이었던 152건 중 실제로는 31건(20.4%)이 relevance 1점 이상으로 판정되었다 — 이는 API 실패로 조용히 0점 처리될 경우 지표가 왜곡될 수 있었음을 보여주는 근거이다.

6.2 정량 지표 결과

relevance-threshold(정답으로 인정하는 최소 점수)를 문서 권장값(2)과 완화값(1) 두 가지로 각각 산출하여 비교했다.

지표	threshold=2(rubric 기본값)	threshold=1(완화 기준)	차이
Recall@5	0.410	0.760	+0.350
Precision@5	0.138	0.450	+0.312
Recall@10	0.460	0.790	+0.330
Precision@10	0.090	0.342	+0.252
nDCG@5	0.499	0.499	동일(0.000)
nDCG@10	0.520	0.520	동일(0.000)
MRR	0.304	0.683	+0.379
정답 0개 질문 수	50 / 100	19 / 100	-31

※ nDCG는 0~3점 원점수를 그대로 gain으로 사용해 threshold에 영향받지 않는 지표이므로 두 조건에서 동일한 값이 나온 것은 정상이다.

6.3 정답 부재(0점) 질문 분석

threshold와 무관하게 정답 후보가 전혀 없었던 19개 질문은 재판정 전후 동일하게 확인되어, 판정 실패의 부작용이 아닌 실제 검색/문서 커버리지 문제로 판단된다.

질문 ID	질문 내용	추정 원인
Q_002	법카 발급받으려면 어디서 신청함?	검색 실패 추정
Q_018	경조사비 신청할 때 청첩장 첨부 필수임?	검색 실패 추정
Q_019	경조금 수령하려면 회계팀에 서류 제출하는 거 맞지?	검색 실패 추정
Q_020	사내 동호회 지원금 받으려면 어디에 서류 내야 해?	문서 부재 추정
Q_046	육아휴직은 입사 후 6개월만 지나면 무조건 승인해줘야 하는 게 맞지?	검색 실패 추정
Q_090	회사 근처 추천할 만한 회식 장소나 맛집 목록 알려줘.	문서 부재(당연)
외 13건	Q_023, Q_024, Q_032, Q_061, Q_064, Q_089, Q_091, Q_092, Q_094, Q_096~098, Q_100 등 — 대부분 인사규정·복지 세부 항목 질의	확인 필요

※ Q_090(맛집 추천)처럼 애초에 사내 문서에 존재할 수 없는 질문은 검색 실패가 아니라 정상 동작으로 봐야 하며, 향후 질문 셋 설계 시 제외를 고려할 필요가 있다.

7. 결과 해석 및 결론

- 검색기 자체의 성능은 예상보다 양호하다. $\text{threshold}=1$ (주제 관련성 인정) 기준 $\text{Recall}@5=0.760$ 으로, 상위 5개 결과 안에 관련 문서가 포함되는 비율이 76%에 달한다.
- 반면 $\text{threshold}=2$ (rubric 권장 기본값) 기준으로는 $\text{Recall}@5$ 가 0.410으로 거의 절반 수준으로 떨어진다. 이는 검색이 '주제가 맞는 chunk'는 잘 찾아오지만, '그 chunk 하나만으로 완결된 답변이 가능한' 수준까지는 도달하지 못하는 경우가 많다는 뜻이다 — 청킹 단위가 작아 하나의 답변 근거가 여러 chunk에 걸쳐 분산되어 있을 가능성을 시사한다.
- $\text{nDCG}@5/@10(0.499 / 0.520)$ 은 threshold 에 영향받지 않는 안정적 지표로, 현재 시스템의 순위 품질 기준선(baseline)으로 활용할 수 있다.
- 100문항 중 19문항(19%)은 threshold 와 무관하게 정답 후보가 전혀 없다. 이 중 상당수(13문항)는 애초에 API 실패로 오염되었던 문항과 겹쳤으나, 재판정 후에도 동일하게 0개로 확인되어 실제 검색/문서 커버리지 문제로 결론지었다.
- qrels 제작 과정에서 재시도 5회 후에도 실패하는 API 오류(5.1%)가 발생했으며, 이 중 20.4%가 실제로는 관련성 있는 판정이었다. 별도 재판정으로 전량 회수했으나, 향후 규모가 커질 경우(예: 질문 수 확대) 동일 이슈가 재발할 수 있어 근본적인 재시도 정책 보강이 필요하다.

8. 한계점

- 본 지표는 LLM Judge가 생성한 초안(qrels_retrieved.csv) 기준이며, rubric에서 요구하는 2점·3점 및 애매 사례에 대한 사람 검토·확정(golden set화)은 수행되었으나 효과 미비한것으로 확인. 최종 확정 라벨과 다소 차이가 발생할 수 있다.
- 후보 pool을 Top-30으로 제한했기 때문에, 실제로는 정답인데 애초에 후보에 들지 못해 라벨 자체가 없는 chunk는 관련성 0으로 처리되어 지표가 과소평가될 가능성이 있다.
- qrels 생성 시 사용한 chunk_size, overlap, embedding backend 등 인덱스 생성 조건이 별도로 기록되지 않아, 향후 인덱스 파라미터를 변경했을 때 이번 결과와 정확히 재현·비교하기 어렵다(index_version 태그만 남음).
- 19개 정답 부재 질문의 정확한 원인(검색 실패 vs. 문서 자체 부재)은 chunk 원문 수동 확인을 거치지 않아 추정 단계이다.
- 본 테스트는 문서 검색(RAG) 모듈에 한정되며, 채팅 UI에서 사용자가 실제로 체감하는 답변 품질(합성된 최종 답변의 정확성)은 별도 평가가 필요하다.

9. 향후 조치 (Action Items)

우선 순위	조치 내용	목적	상태
높음	19개 정답 부재 질문의 chunk 원문을 직접 확인하여 검색 실패인지 문서 커버리지 부재인지 구분	근본 원인 파악	미착수
높음	relevance 2점·3점 및 애매 사례에 대한 사람 검토 추가 진행 → golden set 확정	지표 신뢰도 확보	미착수
중간	청킹 전략(크기·overlap) 재검토 — threshold=1과 threshold=2 격차가 큰 원인 규명	검색 품질 개선	미착수
중간	rag_ground_truth_label.py에 재시도 소진 시 0점이 아닌 별도 상태(UNJUDGED)로 기록하는 로직 추가	재발 방지	미착수
낮음	qrels에 chunk_size·overlap·embedding_backend 기록 추가로 재현성 보강	재현성 확보	미착수